MACHINE LEARNING CANVAS

Designed for: Sistema de Bicicletas Públicas MiBici Designed by: Equipo 21 Date: Octubre 2026 Iteration: 1.0

PREDICTION TASK

Tareas:
- **Regresión:** Predicción de la cantidad de retiros por estación e intervalo horario.

- **Clasificación:** Categorización del nivel de riesgo de desbalance por estación. e.g., *Normal, Riesgo de Desabasto, Riesgo de Saturación.*

- **Clustering:** Agrupación no supervisada de estaciones según patrones de uso horario y ubicación geográfica.

Entidades: Estación de bicicleta en una ventana temporal definida e.g., *Hora/Día.*

Observación de resultados: Se contrasta hora a hora y cierre de cada jornada contra el histórico real de viajes registrados.

DECISIONS

P1: Planificación preventiva de la distribución inicial de bicicletas al inicio del turno.

P1: Generación de alertas prioritarias y despacho focalizado de camiones de rebalanceo hacia zonas críticas.

P3: Rediseño de capacidades de anclaje, reubicación de infraestructura y planificación de expansión del sistema.

VALUE PROPOSITION

Beneficiarios directos: Operadores de flota, equipo de rebalanceo logístico (camiones) y planeadores urbanos del sistema MiBici.

Problemas resueltos:
- Estaciones saturadas (sin anclajes libres) o desabastecidas (sin bicicletas) en horas pico.

- Despliegue reactivo e ineficiente de las unidades de rebalanceo.

- Falta de segmentación clara del comportamiento territorial de las estaciones.

Interfaz e integración:
Dashboard táctico para centro de control e informes de rutas optimizadas de rebalanceo diario.

DATA COLLECTION

Estrategia de ingesta:
- **Migración y estandarización:** Script automatizado que descarga los CSVs crudos de MiBici, estandariza nombres de columnas, asigna tipos de datos y los convierte a parquet.
- **Publicación y Consumo:** Carga los archivos parquet estandarizados a Hugging Face Hub. El pipeline de ML los descarga directamente para realizar limpieza y transformación posterior.

Mantenimiento y calidad: Ingesta por lotes, validación de tipos y esquemas durante conversión a parquet y versionado continuo en Hugging Face Hub.

DATA SOURCES

Fuente Primaria (RAW): Portal de datos abiertos de MiBici (archivos .csv oficiales con históricos de trayectos y catálogo de estaciones).

Data Hub Estructurado (Hugging Face): Repositorio del equipo en Hugging Face Datasets con archivos parquet estandarizados en esquemas y tipos de datos.

Contextual (Opcionales): Calendario de días festivos/laborales y datos meteorológicos.

IMPACT SIMULATION

Costos / Beneficios:
- **Falso Negativo en P2** (no predecir desabasto/saturación): Alto costo por pérdida de usuario y viajes no realizados.
- **Falso Positivo en P2** (alerta falsa): Costo operativo innecesario en traslado de camiones.

Criterios de despliegue: Superar al baseline ingenuo con al menos un 15% de reducción de MAE en P1 y alcanzar un Macro F1 >= 0.75 en P2.

Equidad (Fairness): Evitar sesgos de rebalanceo que prioricen únicamente el centro de la ciudad en detrimento de estaciones periféricas.

MAKING PREDICTIONS

Frecuencia:
- **P1 y P2:** Ejecución programada cada hora o al inicio de los turnos operativos (e.g., 5:00 AM y 2:00 PM).
- **P3:** Ejecución periódica (mensual/trimestral)

Recursos: Entorno de cómputo local/servidor con scripts y almacenamiento eficiente en formato parquet.

BUILDING MODELS

Modelos requeridos: 3 pipelines independientes (*P1: Regresión Linear / Random Forest; P2: Random Forest / XGBoost; P3: K-Means / Clustering Jerárquico*)

Reentrenamiento: Frecuencia mensual o cuando se detecte degradación de métricas (*Data Drift*).

Entorno técnico: Código modular en Python, versionado de experimentos y artefactos gestionados con MLFlow Tracking.

FEATURES

Regresión: Lags temporales, promedios móviles, codificación de hora y día de la semana.

Clasificación: Ratio de presión *(Retiros - Arribos)/capacidad de anclaje*, flujo neto acumulado en horas pico y tasa de rotación.

Clustering: Ratio de uso matutino vs. vespertino, promedio diario de viajes por anclaje y coordenadas espaciales normalizadas.

Procesamiento: Imputación de nulos, eliminación de outliers de duración y escalamiento estándar.

MONITORING

Métricas de ML:
- **P1:** MAE, RMSE, R2.
- **P2:** Macro F1, Precision, Recall, Matriz de confusión.
- **P3:** Coeficiente de Silhouette.

Métricas de Negocio:
- % de reducción de horas con estaciones bloqueadas/vacías
- Optimización de kilómetros recorridos por camiones de rebalanceo.

Revisión: Seguimiento semanal de métricas en MLFlow.

Version 1.2. Created by Louis Dorard, Ph.D. Licensed under a Creative Commons Attribution-ShareAlike 4.0 International License.
Please keep this mention and the link to ownml.co when sharing.

OWNML.CO

What your canvas is for

A filled canvas does 4 jobs, and each one needs certain boxes filled in with care.

- **Deciding what's worth building.** Put each idea on its own canvas and you can compare the ideas on the same terms: what each could gain in a year, and whether the outcomes a model would learn from were ever recorded. That takes dollar amounts in the Impact Simulation box, and a named person in the Value Proposition box who acts on each prediction.
- **Agreeing on what gets built.** Some of the choices that set a system's value look technical, but they're business decisions. What counts as a lost customer: 60 days without buying, or 90? How far ahead do you predict? How many flagged cases can your team act on? On the canvas, business, data and engineering make these choices together, instead of leaving them to whoever writes the code.
- **Knowing when the model is good enough.** The Impact Simulation box sets the performance the model has to reach to pay off. Test the model on enough of the cases you're predicting: 35,000 machine-hours of data can hold just 3 failures, too few to measure anything.
- **Learning after launch.** If acting on a prediction changes the outcome, keep a small share of flagged cases untouched and record that share in the Decisions box, so you can see what your action changed.

Whatever you can't answer is the work left before anyone writes code.

"The Canvas allowed us to structure and focus our delivery sprints. The ML system went live in June 2020 and still is."
— Christian Schiller, Senior IT & Enterprise Architect, Deutsche Telekom

Book a project review

Louis Dorard created the canvas in 2015. Book a free 30-minute call, then send him your canvas draft, or a few lines about the project if you haven't started one. He prepares the call from what you send, and you'll leave knowing where the project is likely to break, and what to check before anyone builds it.

Book a 30-minute call →

Reference the Machine Learning Canvas

If you need to reference the Canvas formally (e.g. in documentation or publications), you may use:

```
@misc{mlc,
  title  = "Machine Learning Canvas",
  author = "Louis Dorard (OWNML)",
  url    = "https://www.ownml.co/",
  year   = "2015"
}
```

"MLC played an essential role in a positive project outcome. It is now being used throughout the organization."
— Daitan, now part of Coforge, a global IT services firm