In [9]:
```
import duckdb
import pandas as pd
from huggingface_hub import __version__ as hf_version

print(f"Pandas: {pd.__version__}")
print(f"DuckDB: {duckdb.__version__}")
print(f"Hugging Face Hub: {hf_version}")
```

```
Pandas: 3.0.6
DuckDB: 1.5.6
Hugging Face Hub: 2.2.0
```

In [10]:
```
import pandas as pd

# Cargar un año específico directamente desde la nube
df = pd.read_parquet("hf://datasets/yako2792/mibici-dataset/mibici-travels-2
df.head()
```

Out[10]:

	Viaje_Id	Usuario_Id	Genero	Año_de_nacimiento	Inicio_del_viaje	Fin_del_viaje
0	26751198	1350606	M	1983.0	2023-01-01 00:00:41	2023-01-01 00:26:52
1	26751199	15163	M	1986.0	2023-01-01 00:04:48	2023-01-01 00:07:46
2	26751200	1534764	M	1987.0	2023-01-01 00:06:49	2023-01-01 00:17:36
3	26751201	1240140	M	1996.0	2023-01-01 00:08:05	2023-01-01 00:09:00
4	26751202	1732214	M	1969.0	2023-01-01 00:09:14	2023-01-01 00:14:57

In [11]:
```
import duckdb

# DuckDB lee la variable 'df' directamente en memoria
query = """
SELECT
    Genero,
    COUNT(*) AS total_viajes,
    ROUND(AVG(DATEDIFF('minute', Inicio_del_viaje, Fin_del_viaje)), 2) AS du
FROM df
GROUP BY Genero
"""

# Regresa un nuevo DataFrame con el resultado de la consulta SQL
df_genero = duckdb.query(query).df()
df_genero
```

Out[11]:

	Genero	total_viajes	duracion_promedio_min
0	M	3119315	10.79
1	F	1154179	11.08
2	NaN	19621	10.94

In [12]:

```
import duckdb

trips_url = "hf://datasets/yako2792/mibici-dataset/mibici-travels-2023.parqu
stations_url = "hf://datasets/yako2792/mibici-dataset/mibici-stations.parque

query_join = f"""
SELECT
    t.Viaje_Id,
    t.Inicio_del_viaje,
    t.Fin_del_viaje,

    -- Información de la Estación de ORIGEN
    t.Origen_Id,
    so.name AS origen_nombre,
    so.latitude AS origen_lat,
    so.longitude AS origen_lon,
    so.dpcapacity AS origen_capacidad,

    -- Información de la Estación de DESTINO
    t.Destino_Id,
    sd.name AS destino_nombre,
    sd.latitude AS destino_lat,
    sd.longitude AS destino_lon,
    sd.dpcapacity AS destino_capacidad

FROM '{trips_url}' t
LEFT JOIN '{stations_url}' so ON t.Origen_Id = so.id
LEFT JOIN '{stations_url}' sd ON t.Destino_Id = sd.id
LIMIT 10
"""

df_enriquecido = duckdb.query(query_join).df()
df_enriquecido
```

Out[12]:

	Viaje_Id	Inicio_del_viaje	Fin_del_viaje	Origen_Id	origen_nombre	origen_lat	
0	30508243	2023-10-01 00:00:15	2023-10-01 00:06:40	255	(GDL-182) C. General Coronado / C. Manuel Acu	20.684342	-1
1	30508244	2023-10-01 00:00:22	2023-10-01 00:08:28	150	(TLQ-009) C. Progreso / C. Juárez	20.638160	-
2	30508245	2023-10-01 00:00:44	2023-10-01 00:11:19	79	(GDL-077) C. Argentina / C. Pedro Moreno	20.675631	-
3	30508246	2023-10-01 00:00:45	2023-10-01 00:06:32	44	(GDL-042) C. Bernardo de Balbuena /Av Hidalgo	20.676628	-
4	30508247	2023-10-01 00:00:50	2023-10-01 00:08:46	260	(GDL-187) Av. 16 de Septiembre / C. Priscilia	20.672639	-
5	30508248	2023-10-01 00:01:04	2023-10-01 00:18:27	72	(GDL-070) Av. La Paz / C. Juan de Ojeda	20.671455	-1
6	30508249	2023-10-01 00:01:12	2023-10-01 00:16:13	175	(GDL-108) C. Hospital / C. Alameda	20.685860	-1
7	30508250	2023-10-01 00:01:16	2023-10-01 00:11:04	50	(GDL-048) C. Constancio Hernández/ Av. Juaréz	20.674721	-1
8	30508251	2023-10-01 00:01:20	2023-10-01 00:01:30	50	(GDL-048) C. Constancio Hernández/ Av. Juaréz	20.674721	-1
9	30508252	2023-10-01 00:01:36	2023-10-01 00:11:04	50	(GDL-048) C. Constancio Hernández/ Av. Juaréz	20.674721	-1

In [13]:

```
from pathlib import Path
from huggingface_hub import snapshot_download

HF_DATASET_REPO = "yako2792/mibici-dataset"
PARQUET_DATA_DIR = Path("data/parquet")


def download_all_parquets(
    repo_id: str = HF_DATASET_REPO,
    target_dir: Path = PARQUET_DATA_DIR
```

```
) -> None:
    target_dir.mkdir(parents=True, exist_ok=True)
    print(f"Downloading all parquets from {repo_id} to {target_dir}")

    snapshot_download(
        repo_id=repo_id,
        repo_type="dataset",
        local_dir=target_dir,
        allow_patterns="*.parquet"
    )

    print(f"All parquets downloaded to {target_dir}")


download_all_parquets()
```

```
Downloading all parquets from yako2792/mibici-dataset to data/parquet
Downloading bytes:           |  0.00B
Reconstructing (incomplete total...): |          |  0.00B /  0.00B
Fetching 14 files:   0%|          | 0/14 [00:00<?, ?it/s]
All parquets downloaded to data/parquet
```

In [14]:

```
from pathlib import Path
import duckdb

# Rutas locales a tus archivos .parquet (ajusta la carpeta si usas data/inte
parquet_dir = Path("data/parquet")
trips_path = parquet_dir / "mibici-travels-2023.parquet"
stations_path = parquet_dir / "mibici-stations.parquet"

query_join = f"""
SELECT
    t.Viaje_Id,
    t.Inicio_del_viaje,
    t.Fin_del_viaje,

    -- Información de la Estación de ORIGEN
    t.Origen_Id,
    so.name AS origen_nombre,
    so.latitude AS origen_lat,
    so.longitude AS origen_lon,
    so.dpcapacity AS origen_capacidad,

    -- Información de la Estación de DESTINO
    t.Destino_Id,
    sd.name AS destino_nombre,
    sd.latitude AS destino_lat,
    sd.longitude AS destino_lon,
    sd.dpcapacity AS destino_capacidad

FROM '{trips_path}' t
LEFT JOIN '{stations_path}' so ON t.Origen_Id = so.id
LEFT JOIN '{stations_path}' sd ON t.Destino_Id = sd.id
LIMIT 10
"""
```

```
df_enriquecido = duckdb.query(query_join).df()
df_enriquecido
```

Out[14]:

	Viaje_Id	Inicio_del_viaje	Fin_del_viaje	Origen_Id	origen_nombre	origen_lat	
0	28897410	2023-06-01 00:00:40	2023-06-01 00:09:26	20	(GDL-018) Av. México / C. Manuel M. Diéguez	20.679296	-1
1	28897411	2023-06-01 00:00:46	2023-06-01 00:13:33	20	(GDL-018) Av. México / C. Manuel M. Diéguez	20.679296	-1
2	28897412	2023-06-01 00:00:55	2023-06-01 00:01:10	273	(GDL-200) Av. Alcalde /Av. Manuel A. Camacho	20.694060	-1
3	28897413	2023-06-01 00:00:59	2023-06-01 00:12:41	273	(GDL-200) Av. Alcalde /Av. Manuel A. Camacho	20.694060	-1
4	28897414	2023-06-01 00:01:20	2023-06-01 00:12:33	273	(GDL-200) Av. Alcalde /Av. Manuel A. Camacho	20.694060	-1
5	28897415	2023-06-01 00:01:42	2023-06-01 00:14:16	309	(ZPN-064) C. Sto de Aquino / Av. Sta Teresa	20.666993	-1
6	28897416	2023-06-01 00:02:32	2023-06-01 00:06:24	72	(GDL-070) Av. La Paz / C. Juan de Ojeda	20.671455	-1
7	28897418	2023-06-01 00:02:54	2023-06-01 00:17:29	58	(GDL-056) Av. 16 de Sept. / C. Miguel Blanco	20.671971	-1
8	28897421	2023-06-01 00:05:07	2023-06-01 00:07:48	44	(GDL-042) C. Bernardo de Balbuena /Av Hidalgo	20.676628	-1
9	28897422	2023-06-01 00:05:10	2023-06-01 00:14:36	159	(GDL-092) Calz Federalismo / Av Plan San Luis	20.696121	-1

In [ ]: